

МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра МО ЭВМ

ОТЧЕТ
по лабораторной работе №4
по дисциплине «Построение и анализ алгоритмов»
Тема: Алгоритм Кнута-Морриса-Пратта

Студент гр. 8303

Кибардин А.Б.

Преподаватель

Фирсов М.А.

Санкт-Петербург

2020

Цель работы.

Изучение алгоритма Кнута-Морриса-Пратта для поиска всех вхождений подстроки в исходной строке.

Формулировка задачи 1.

Реализуйте алгоритм КМП и с его помощью для заданных шаблона P ($|P| \leq 15000$) и текста T ($|T| \leq 5000000$) найдите все вхождения PP в T .

Вход:

Первая строка - P

Вторая строка - T

Выход:

индексы начал вхождений P в T , разделенных запятой, если PP не входит в TT , то вывести -1

Sample Input:

ab

abab

Sample Output:

0,2

Формулировка задачи 2.

Заданы две строки A ($|A| \leq 5000000$) и B ($|B| \leq 5000000$).

Определить, является ли A циклическим сдвигом B (это значит, что A и B имеют одинаковую длину и A состоит из суффикса B , склеенного с префиксом B). Например, defabc является циклическим сдвигом abcdef.

Вход:

Первая строка - A

Вторая строка - B

Выход:

Если A является циклическим сдвигом B , индекс начала строки B в A , иначе вывести -1 . Если возможно несколько сдвигов вывести первый индекс.

Sample Input:

defabc

abcdef

Sample Output:

3

Индивидуализация.

Вар. 2. Оптимизация по памяти: программа должна требовать $O(m)$ памяти, где m - длина образца. Это возможно, если не учитывать память, в которой хранится строка поиска.

Описание алгоритма КМП.

Первым шагом алгоритм вычисляет префикс-функцию для шаблона. На следующем шаге производится сравнение шаблона и текста. При совпадении символов увеличиваем счетчики текста (k) и шаблона (l) на единицу. При несовпадении происходит откат к предыдущему совпавшему префиксу. Если счетчик шаблона стал равен длине строки шаблона, то слово найдено, его позиция $k-l$ записывается в вектор результата, счетчик шаблона обнуляется, а текста инкрементируется, цикл повторяется. Алгоритм заканчивает работу, когда он дойдет до конца строки. Если совпадения в тексте отсутствуют, то в массив индексов записывается -1.

Сложности алгоритма.

Сложность алгоритма по операциям $O(n+m)$, где n – количество символов в тексте, m – количество символов в шаблоне.

Сложность алгоритма $O(m)$, где m – число символов в строке шаблоне.

Описание циклического сдвига.

Алгоритм является модификацией КМП. Аналогично КМП при несовпадении происходит изменение счетчиков. При совпадении проверяется, является ли данное совпадение первым в цепочке. Если оно первое, то позиция в промежуточный результат, инкрементируются счетчики строки сдвига (k) и исходной строки (l). Если счетчик строки сдвига равен длине строки сдвига производится проверка количество проходов по строке. Если алгоритм проходится в первый раз по строке, то счетчик сдвига обнуляется и флаг цикла становится равным true. При повторном достижении конца строки алгоритм завершает свою работу, возвращая -1.

Если на очередной итерации счетчик исходной строки равен длине исходной строки, то алгоритм завершает свою работу, возвращая индекс начала исходной строки в строке сдвига.

Сложности алгоритма.

Сложность алгоритма по операциям $O(n+n) = O(n)$, где n – количество символов строке сдвига.

Сложность алгоритма $O(n)$, где n – число символов в строке сдвига.

Префикс-функция.

Префикс-функция от строки и позиции в ней – длина наибольшего собственного префикса подстроки, который одновременно является суффиксом этой подстроки. То есть, в начале подстроки длины нужно найти такой префикс максимальной длины, который был бы суффиксом данной подстроки.

В программе префикс-функция для очередного символа рассчитывается на основе предыдущего. Так, если символ с индексом равным префикс-функции и текущий символ строки равны, то префикс-функция текущего символа равна предыдущее значение префикс-функции плюс единица. В случае, когда символы не равны, рассматривается префикс предыдущего символа.

Описание функций.

`std::vector<int> prefix_function (std::string s)` – функция построения префикс функции. Возвращает вектор значений префикс-функции для обрабатываемой строки.

`s` – обрабатываемая строка.

`int cyclicShift(std::string& text, std::string& shiftText)` – функция проверяющая, является ли строка `shiftText` циклическим сдвигом строки `text`. Возвращает индекс начала строки `text` в строки `shiftText`. Если строка `shiftText` не является циклическим сдвигом, возвращается -1.

`std::vector<int> kmp(std::string& pattern, std::string& text)` – функция поиска вхождений подстроки в строку с помощью алгоритма КМП. Возвращается вектор индексов, с которых найдено совпадение. Если совпадений нет, то возвращается вектор с единственным элементом -1.

`pattern` – строка-шаблон.

`text` – строка исходного текста, в которой ищется шаблон.

Тестирование.

Алгоритм КМП

ab

abab

0,2

Process finished with exit code 0

ba

abababaaabababbababbbbaaa

1,3,5,9,11,14,16,21

Process finished with exit code 0

|

dddd

aaaaa

-1

Process finished with exit code 0

abcabd

abcabeabcabcabd

prefix function: 0 0 0 1 2 0

found equal symbols, pattern[0] = a, text[0] = a

found equal symbols, pattern[1] = b, text[1] = b

found equal symbols, pattern[2] = c, text[2] = c

found equal symbols, pattern[3] = a, text[3] = a

found equal symbols, pattern[4] = b, text[4] = b

found different symbol, pattern[5] = d, text[5] = e

shift l, k = 5, l = 2

found different symbol, pattern[5] = c, text[2] = e

shift l, k = 5, l = 0

found different symbol, pattern[5] = a, text[0] = e

k++, k = 6, l = 0

found equal symbols, pattern[6] = a, text[0] = a

found equal symbols, pattern[7] = b, text[1] = b

found equal symbols, pattern[8] = c, text[2] = c

found equal symbols, pattern[9] = a, text[3] = a

found equal symbols, pattern[10] = b, text[4] = b

found different symbol, pattern[11] = d, text[5] = c

shift l, k = 11, l = 2

found equal symbols, pattern[11] = c, text[2] = c

found equal symbols, pattern[12] = a, text[3] = a

found equal symbols, pattern[13] = b, text[4] = b

found equal symbols, pattern[14] = d, text[5] = d

found pattern at k = 9

9

Process finished with exit code 0

```

gts
abcdefghgtsabcdefghgts
prefix function: 0 0 0
found different symbol, pattern[0] = g, text[0] = a
k++, k = 1, l = 0
found different symbol, pattern[1] = g, text[0] = b
k++, k = 2, l = 0
found different symbol, pattern[2] = g, text[0] = c
k++, k = 3, l = 0
found different symbol, pattern[3] = g, text[0] = d
k++, k = 4, l = 0
found different symbol, pattern[4] = g, text[0] = e
k++, k = 5, l = 0
found different symbol, pattern[5] = g, text[0] = f
k++, k = 6, l = 0
found equal symbols, pattern[6] = g, text[0] = g
found different symbol, pattern[7] = t, text[1] = h
shift l, k = 7, l = 0
found different symbol, pattern[7] = g, text[0] = h
k++, k = 8, l = 0
found equal symbols, pattern[8] = g, text[0] = g
found equal symbols, pattern[9] = t, text[1] = t
found equal symbols, pattern[10] = s, text[2] = s
found pattern at k = 8
found different symbol, pattern[11] = g, text[0] = a
k++, k = 12, l = 0
found different symbol, pattern[12] = g, text[0] = b
k++, k = 13, l = 0

```

```

found different symbol, pattern[13] = g, text[0] = c
k++, k = 14, l = 0
found different symbol, pattern[14] = g, text[0] = d
k++, k = 15, l = 0
found different symbol, pattern[15] = g, text[0] = e
k++, k = 16, l = 0
found different symbol, pattern[16] = g, text[0] = f
k++, k = 17, l = 0
found equal symbols, pattern[17] = g, text[0] = g
found different symbol, pattern[18] = t, text[1] = h
shift l, k = 18, l = 0
found different symbol, pattern[18] = g, text[0] = h
k++, k = 19, l = 0
found equal symbols, pattern[19] = g, text[0] = g
found equal symbols, pattern[20] = t, text[1] = t
found equal symbols, pattern[21] = s, text[2] = s
found pattern at k = 19
8,19
Process finished with exit code 0
|

```

Циклический сдвиг

defabc

abcdef

3

Process finished with exit code 0

abcabcabcabcabc

bcabcabcabcabca

1

Process finished with exit code 0

sbtnpwrlflb

bsbtnpwrlfl

-1

Process finished with exit code 0

defabcabc

abcdefabc

prefix function: 0 0 0 0 0 0 1 2 3

found different symbol, shiftText[0] = d, text[0] = a

k++, k = 1, l = 0

found different symbol, shiftText[1] = e, text[0] = a

k++, k = 2, l = 0

found different symbol, shiftText[2] = f, text[0] = a

k++, k = 3, l = 0

found equal symbols, shiftText[3] = a, text[0] = a

found equal symbols, shiftText[4] = b, text[1] = b

found equal symbols, shiftText[5] = c, text[2] = c

found different symbol, shiftText[6] = a, text[3] = d

shift l, k = 6, l = 0

found equal symbols, shiftText[6] = a, text[0] = a

found equal symbols, shiftText[7] = b, text[1] = b

found equal symbols, shiftText[8] = c, text[2] = c

end shiftText reached , k = 0, l = 3

found equal symbols, shiftText[0] = d, text[3] = d

found equal symbols, shiftText[1] = e, text[4] = e

found equal symbols, shiftText[2] = f, text[5] = f

found equal symbols, shiftText[3] = a, text[6] = a

found equal symbols, shiftText[4] = b, text[7] = b

found equal symbols, shiftText[5] = c, text[8] = c

end text reached at k = 5

result with cycle: 6

6

Process finished with exit code 0

.

Вывод.

В ходе выполнения лабораторной работы были получены знания по работе с алгоритмом Кнута-Морриса-Пратта для поиска всех вхождений подстроки в заданную строку. Так же были написаны функции, реализующие алгоритм Кнута-Морриса-Пратта, вычисление префикс-функции и проверки является ли одна строка циклическим сдвигом другой.

Приложение А. Исходный код.

Kmp.cpp

```
#include <iostream>
#include <vector>

#define debug

std::vector<int> prefix_function (std::string s) {
    int n = s.length();
    std::vector<int> pi(n, 0);           //создаем вектор необходимого размера
    for (int i=1; i<n; ++i) {
        int j = pi[i-1];               //вычисляем новое значение п-ф, про
        while (j > 0 && s[i] != s[j])   //проверяем до тех пор, пока не дойдем до 0, либо пока
            j = pi[j-1];               //символы не совпадут
        if (s[i] == s[j])              //при совпадении символов увеличиваем п-ф на единицу
            ++j;
        pi[i] = j;
    }
}

#ifdef debug
    std::cout << "prefix function: ";
    for(auto iter : pi)
        std::cout << iter << " ";
    std::cout << std::endl;
#endif
return pi;
}

std::vector<int> kmp(std::string& pattern, std::string& text)    //алгоритм кнута-морриса-прамта
{
    std::vector<int> result;
    std::vector<int> prefix;
    if(pattern.size() > text.size())           //проверка на корректность длины шаблона
    {
#ifdef debug
        std::cout << "length of text less than pattern" << std::endl;
#endif
        result.push_back(-1);
        return result;
    }
    prefix = prefix_function(pattern);          //задаем префикс-функцию
    for(int k = 0, l = 0; k < text.size(); )
        if(text[k] == pattern[l])             //при нахождении одинаковых символов сдвигаем счетчики
        {
#ifdef debug
            std::cout << "found equal symbols, pattern[" << k << "] = " << pattern[l] << ", " << "text[" << l << "] = " <<
            text[k] << std::endl;
#endif
            k++;
            l++;
            if(l == pattern.size())            //обнуляем счетчик шаблона, если он найден в тексте
            {
#ifdef debug
                std::cout << "found pattern at k = " << k - l << std::endl;
#endif
                result.push_back(k - l);
                l = 0;
            }
        }
        else
        {
#ifdef debug
            std::cout << "found pattern at k = " << k - l << std::endl;
#endif
            result.push_back(k - l);
            l = 0;
        }
    }
}
```

```

        std::cout << "found different symbol, pattern[" << k << "] = " << pattern[l] << ", " << "text[" << l << "] = " <<
text[k] << std::endl;
#endif
        if(l == 0)
        {
            k++;
        }
        //при несовпадении шаблона и текста с первого символа
        //увеличиваем счетчик текста, иначе счетчику шаблона
        //присваиваем предыдущее значение префикс-функции
#ifdef debug
        std::cout << "k++, k = " << k << ", l = " << l << std::endl;
#endif
    } else
    {
        l = prefix[l-1];
    }
#ifdef debug
    std::cout << "shift l, k = " << k << ", l = " << l << std::endl;
#endif
    }
    }
    if(result.empty())
    {
        result.push_back(-1);
    }
    return result;
}

int main() {
    std::vector<int> result;
    std::string P, T;
    std::cin >> P;
    std::cin >> T;
    result = kmp(P, T);
    for(auto iter = result.begin(); iter != result.end(); iter++)
    {
        std::cout << *iter;
        if(iter + 1 != result.end())
            std::cout << ",";
    }
    return 0;
}

```

cyclicShift.cpp

```

#include <iostream>
#include <vector>

#define debug

std::vector<int> prefix_function (std::string s) {
    int n = s.length();
    std::vector<int> pi(n, 0);
    for (int i=1; i<n; ++i) {
        int j = pi[i-1];
        while (j > 0 && s[i] != s[j])
            j = pi[j-1];
        if (s[i] == s[j])
            ++j;
        pi[i] = j;
    }
}

#ifdef debug
std::cout << "prefix function: ";
for(auto iter : pi)
    std::cout << iter << " ";
std::cout << std::endl;
#endif

```

```

    return pi;
}

int cyclicShift(std::string& text, std::string& shiftText)
{
    bool cycle = false;
    int result = -1;
    std::vector<int> prefix;
    if(text.size() != shiftText.size())           //-выходим из функции, так как длины строк не равны
    {
        #ifdef debug
            std::cout << "strings have different lengths " << std::endl;
        #endif
        return -1;
    }
    prefix = prefix_function(text);               //-вычисляем префикс-функцию
    for(int k = 0, l = 0; k < shiftText.size(); )
        if(shiftText[k] == text[l])              //-при нахождении одинаковых символов сдвигаем счетчики
        {
            if(result == -1)                      //-если до текущего шага не было найдено совпадений, то
                result = k;                      //записываем индекс первого символа в сдвиге
        #ifdef debug
            std::cout << "found equal symbols, shiftText[" << k << "] = " << shiftText[k] << ", " << "text[" << l << "] = "
            << text[l] << std::endl;
        #endif
            k++;
            l++;
            if(l == text.size())                  //-при достижении конца строки T возвращаем индекс первого
            {                                    //символа из T в строке сдвига
        #ifdef debug
            std::cout << "end text reached at k = " << k - 1 << std::endl;
            if(cycle)
            {
                std::cout << "result with cycle: " << result << std::endl;
            } else
            {
                std::cout << "result without cycle: " << result << std::endl;
            }
        #endif
            return result;
        }
        if(k == shiftText.size())                //-при достижении конца строки сдвига, обнуляем ее счетчик
        {
            k = 0;
            if(cycle)                            //при повторном достижении конца строки завершаем работу
                return -1;
            cycle = true;
        #ifdef debug
            std::cout << "end shiftText reached , k = " << k << ", l = " << l << std::endl;
        #endif
        }
        } else
        {
        #ifdef debug
            std::cout << "found different symbol, shiftText[" << k << "] = " << shiftText[k] << ", " << "text[" << l << "] = "
            << text[l] << std::endl;
        #endif
            result = -1;                          //-при несовпадении символов, удаляем запись о нахождении
            //первого символа
            if(l == 0)                            //-увеличение счетчика строки сдвига
            {
                k++;
            }
        }
    }
}

```

```

#ifdef debug
    std::cout << "k++, k = " << k << ", l = " << l << std::endl;
#endif
    } else
    {
        //присваиваем счетчику искомой строки предыдущее значение
        l = prefix[l-1]; // префикс-функции
#ifdef debug
        std::cout << "shift l, k = " << k << ", l = " << l << std::endl;
#endif
    }
}
#ifdef debug
    std::cout << "not a cycle shift " << std::endl;
#endif
    return result;
}

int main() {
    std::string shiftText, text;
    std::cin >> shiftText;
    std::cin >> text;
    std::cout << cyclicShift(text, shiftText);
    return 0;
}

```